TEMPLATE IDE PRODUK INOVATIF BERBASIS AI

Dari Kebutuhan Pengguna Hingga Pembuktian Metode AI pada Fitur Terpilih

Nama	:	**Rama Adhi Saputra**
NIM	:	A11.2024.15847
Kelas	:	A11.4507
Dosen Pengampu	:	Abu Salam, M.Kom
Mata Kuliah	:	Data Mining

1. PRODUK UTAMA & ALASAN PENGGUNAAN AI/ML

Nama Produk: DermaSpot

Pengguna Sasaran:

Masyarakat umum — terutama mereka yang tinggal di daerah dengan akses terbatas ke dokter spesialis kulit (dermatolog), serta individu yang ingin melakukan pemeriksaan mandiri (self-screening) sebagai langkah pencegahan dini terhadap risiko kanker kulit melanoma.

Inovasi Inti:

DermaSpot menyediakan fitur klasifikasi gambar (image classification) berbasis AI. Pengguna cukup mengunggah foto area kulit yang mencurigakan melalui website, dan sistem akan memberikan hasil deteksi risiko secara instan — apakah lesi kulit tersebut tergolong Jinak (Benign) atau Berpotensi Ganas (Malignant/Melanoma) — dilengkapi dengan confidence score dan rekomendasi tindak lanjut.

Alasan Penggunaan AI:

Secara konvensional, diagnosis kanker kulit memerlukan pemeriksaan langsung oleh dokter spesialis, yang tidak selalu mudah diakses — terutama di wilayah dengan keterbatasan fasilitas kesehatan. Di Indonesia, rasio dermatolog terhadap penduduk masih sangat rendah. Banyak kasus kanker kulit stadium lanjut

terjadi akibat keterlambatan deteksi. Dengan AI berbasis Image Classification, proses skrining awal dapat dilakukan secara cepat, murah, dan dapat diakses siapa saja hanya berbekal browser dan kamera HP.

2. PETA KEBUTUHAN FITUR PRODUK

Berikut adalah pemetaan fitur produk DermaSpot beserta tugas AI/ML, data input-output, dan prioritas pengerjaan:

Fitur & Manfaat	Tugas AI/ML	Data Input → Keluaran	Prioritas / Data
F1 — Klasifikasi Lesi Kulit (Utama): Mendeteksi apakah lesi kulit berisiko melanoma berdasarkan foto	Image Classification (Binary: Benign vs Malignant)	Foto kulit (RGB, 224×224px) → Label risiko + confidence score	Tinggi / Tersedia (HAM10000)
F2 — Segmentasi Area Lesi: Menandai batas tepi lesi secara visual	Image Segmentation (U-Net / Mask R-CNN)	Foto kulit (RGB) → Overlay masking area lesi	Sedang / Tersedia (ISIC Archive)
F3 — Pemantauan Perkembangan: Melacak perubahan ukuran & bentuk lesi dari waktu ke waktu	Time-Series Analysis pada metadata gambar	Histori foto (time-stamped) → Grafik tren risiko	Rendah / Belum Tersedia

Fitur yang dipilih sebagai fokus penelitian adalah F1 (Klasifikasi Lesi Kulit) karena memiliki prioritas tertinggi, dataset tersedia secara publik, dan dapat langsung diimplementasikan ke website. F2 dan F3 merupakan rencana pengembangan lanjutan.

3. FOKUS PENELITIAN, LITERATUR & KEBARUAN

3.1. Fitur Terpilih dan Rumusan Masalah

Fitur Terpilih: F1 — Klasifikasi Lesi Kulit

Kendala Utama: Ketidakseimbangan data (imbalanced data) — kasus Melanoma (ganas) hanya sekitar 11% dari total dataset, sehingga model AI cenderung bias ke kelas mayoritas (jinak).

Rumusan Masalah: *"Bagaimana pengaruh penerapan teknik Class Weighting pada arsitektur Transfer Learning MobileNetV2 terhadap peningkatan nilai Recall dalam klasifikasi kanker kulit melanoma pada dataset HAM10000 yang tidak seimbang?"*

3.2. Studi Terdahulu

Berikut adalah ringkasan empat penelitian terdahulu yang relevan beserta keterbatasan masing-masing:

Peneliti & Tahun	Pendekatan & Hasil	Keterbatasan	Research Gap
Esteva et al. (2017) — Nature	Deep CNN (Inception V3), 129.450 gambar, akurasi setara dermatolog manusia	Model sangat berat, tidak feasible untuk web, tidak membahas imbalanced data	Butuh model ringan untuk web deployment
Goyal et al. (2020) — IEEE Access	ResNet-50 pada dataset ISIC, akurasi keseluruhan ~85%	Recall kelas Melanoma hanya ~68%, tidak ada strategi penanganan imbalanced	Recall kelas minoritas rendah — perlu Class Weighting
Chaturvedi et al. (2022) — Computers in Biology and Medicine	MobileNet untuk klasifikasi lesi kulit pada perangkat mobile	Belum menerapkan penalti khusus (Class Weighting) untuk imbalanced data	Model MobileNet perlu dikombinasikan dengan Class Weighting

Kassem et al. (2020) — IEEE Access	Transfer Learning MobileNetV2 pada dataset dermoskopi, akurasi kompetitif	Evaluasi hanya Accuracy dan F1, tidak mengoptimasi Recall sebagai prioritas	Perlu orientasi metrik Recall untuk konteks deteksi kanker

3.3. Kontribusi dan Kebaharuan Penelitian

Berdasarkan research gap yang teridentifikasi dari empat studi di atas, penelitian ini mengusulkan kombinasi MobileNetV2 + Class Weighting yang secara bersamaan mengatasi dua masalah utama:

- Model berat yang tidak feasible untuk web deployment → diatasi dengan MobileNetV2 (~14 MB)
- Imbalanced data yang menyebabkan bias prediksi → diatasi dengan Class Weighting (penalti ~8× untuk kelas ganas)
- Orientasi metrik yang tidak sesuai konteks medis → diatasi dengan menjadikan Recall sebagai metrik utama (target ≥ 85%)

Kebaruan utama penelitian ini adalah pengujian eksplisit bahwa Class Weighting secara signifikan meningkatkan Recall pada model ringan berbasis MobileNetV2 yang dapat langsung di-deploy ke website Streamlit.

4. RANCANGAN DATASET & ATRIBUT

4.1. Sumber & Deskripsi Dataset

Nama Dataset: HAM10000 (Human Against Machine with 10000 training images)

Sumber: ISIC (International Skin Imaging Collaboration) — tersedia gratis di Kaggle dan Harvard Dataverse

Lisensi: CC BY-NC-SA 4.0 (bebas untuk penelitian akademik)

Jumlah Data: 10.015 foto lesi kulit berlabel, format JPEG

4.2. Atribut Dataset

Atribut	Tipe Data	Contoh Nilai	Relevansi
image_id	String	ISIC_0024306	Identitas unik tiap gambar
dx	Kategorikal	mel, nv, bkl, bcc, akiec, df, vasc	Label diagnosis — TARGET UTAMA (disederhanakan menjadi Jinak/Ganas)
dx_type	Kategorikal	histo, follow_up, consensus	Metode konfirmasi diagnosis
age	Numerik	45.0	Usia pasien — atribut pendukung
sex	Kategorikal	male, female	Jenis kelamin pasien
localization	Kategorikal	back, lower extremity, trunk	Lokasi lesi di tubuh

4.3. Penyederhanaan Label (Binary Classification)

Label asli HAM10000 memiliki 7 kelas diagnosis. Untuk penelitian ini, label disederhanakan menjadi klasifikasi biner (Supervised Learning):

- Label 1 (Ganas/Malignant): mel (Melanoma), akiec (Actinic Keratosis), bcc (Basal Cell Carcinoma)

- Label 0 (Jinak/Benign): nv (Melanocytic Nevi), bkl (Benign Keratosis), df (Dermatofibroma), vasc (Vascular Lesions)

Penyederhanaan ini bertujuan memberikan sinyal peringatan dini yang jelas: "perlu ke dokter" atau "tidak perlu khawatir".

4.4. Strategi Preprocessing & Kualitas Data

- Penghapusan duplikat: HAM10000 mengandung ~600 gambar duplikat — akan dihapus sebelum split
- Resize: Semua gambar diubah ke resolusi 224×224 piksel (standar input MobileNetV2)
- Normalisasi: Nilai piksel dinormalisasi dari [0–255] menjadi [0–1]
- Data Augmentation: Rotasi, flip horizontal/vertikal, zoom, dan brightness adjustment — HANYA diterapkan pada data train untuk mencegah data leakage
- Stratified Split: Pembagian 80% Train / 10% Validasi / 10% Test dengan proporsi kelas yang terjaga di setiap subset

5. METODOLOGI PENELITIAN DAN PILIHAN METODE AI/ML

5.1. Metodologi (Urutan Kerja)

Identifikasi Masalah → Studi Literatur (HAM10000 & penelitian terdahulu) → Akuisisi Data → Preprocessing & Augmentasi Gambar → Exploratory Data Analysis (EDA) → Pemodelan AI → Evaluasi & Komparasi Metrik → Integrasi ke Website Streamlit

5.2. Perbandingan Metode

Aspek	**Baseline — VGG-16**	**Usulan — MobileNetV2 + Class Weighting**

Arsitektur	VGG-16	MobileNetV2
Strategi Imbalanced	Tidak ada	Class Weighting (Jinak:1.0 / Ganas:~8.1)
Ukuran Model	~528 MB	~14 MB
Cocok untuk Web	Tidak (terlalu berat)	Ya (ringan, cepat)
Fokus Metrik	Accuracy	Recall / Sensitivity

5.3. Alasan Pemilihan Metode

MobileNetV2 dipilih karena merupakan arsitektur Transfer Learning yang telah pre-trained pada jutaan gambar umum (ImageNet), sehingga kemampuan ekstraksi fitur visualnya sudah sangat kuat. Dibandingkan alternatif lain:

1. vs ResNet-50: MobileNetV2 jauh lebih ringan (~14 MB vs ~100 MB) dengan trade-off akurasi yang masih acceptable untuk web deployment
2. vs VGG-16: VGG-16 berukuran ~528 MB dan lambat saat inferensi — tidak cocok untuk website dengan banyak pengguna
3. vs Random Forest/SVM: Algoritma tabular, tidak dirancang untuk data gambar — tidak relevan untuk tugas image classification
4. vs SMOTE: SMOTE menghasilkan gambar sintetis tidak realistis secara medis; Class Weighting lebih aman karena tidak membuat data baru

5.4. Strategi Pemodelan

Training dilakukan dalam dua fase:

1. Fase 1 — Feature Extraction (5 epoch): Layer MobileNetV2 di-freeze, hanya layer classifier baru yang dilatih. Learning rate: 0.001

2. Fase 2 — Fine Tuning (10 epoch): Unfreeze 50 layer terakhir MobileNetV2, latih ulang dengan learning rate lebih kecil (0.0001) untuk menghindari catastrophic forgetting

6. RANCANGAN EKSPERIMEN & EVALUASI

6.1. Skenario Eksperimen

Penelitian ini menjalankan tiga eksperimen secara berurutan untuk mengisolasi pengaruh masing-masing komponen:

1. Eksperimen 1 (Baseline 1): VGG-16 tanpa Class Weighting — sebagai baseline arsitektur berat
2. Eksperimen 2 (Baseline 2): MobileNetV2 tanpa Class Weighting — mengisolasi pengaruh arsitektur saja
3. Eksperimen 3 (Usulan): MobileNetV2 + Class Weighting — model final yang diusulkan

Pemisahan Eksperimen 2 dan 3 penting untuk menjawab: "Mana yang lebih berkontribusi — arsitektur MobileNetV2 atau teknik Class Weighting?"

6.2. Metrik Evaluasi

Metrik utama adalah Recall (Sensitivity) dengan target ≥ 85%, karena dalam konteks medis, False Negative (orang sakit kanker tidak terdeteksi) adalah kesalahan paling fatal. Metrik pendukung:

- Precision (target ≥ 70%): Dari yang diprediksi ganas, berapa yang benar-benar ganas
- F1-Score (target ≥ 75%): Keseimbangan antara Recall dan Precision
- AUC-ROC (target ≥ 0.85): Kemampuan model membedakan kelas secara keseluruhan
- Inference Time (target ≤ 3 detik): Kecepatan prediksi per gambar di website

6.3. Proyeksi Hasil Eksperimen

Berikut adalah tabel proyeksi hasil berdasarkan literatur terkait (akan diganti hasil aktual saat UAS):

Metrik	Eks.1: VGG-16	Eks.2: MobileNetV2	Eks.3: MobileNetV2 + CW (Usulan)
Recall	~65%	~72%	≥ 85% (target)
Precision	~78%	~75%	≥ 70%
F1-Score	~71%	~73%	≥ 77%
AUC-ROC	~0.79	~0.83	≥ 0.87
Inference Time	~2.1 detik	~0.8 detik	≤ 0.8 detik
Ukuran Model	~528 MB	~14 MB	~14 MB

6.4. Cara Menjawab Rumusan Masalah

Rumusan masalah terjawab dengan membandingkan Recall Eksperimen 2 vs Eksperimen 3. Jika Recall Eks.3 > Recall Eks.2 secara signifikan (selisih ≥ 5%), maka terbukti bahwa Class Weighting berkontribusi nyata dalam meningkatkan Recall model MobileNetV2 pada dataset imbalanced.

7. RENCANA PELAKSANAAN & LUARAN

7.1. Timeline Penelitian (8 minggu)

Fase	Minggu	Kegiatan
Fase 1: Fondasi	Minggu 1–2	Setup environment, download HAM10000, preprocessing, EDA, stratified split 80/10/10
Fase 2: Pemodelan	Minggu 3–4	Training Baseline (VGG-16), training MobileNetV2, implementasi Class Weighting, simpan model .h5

Fase 3: Evaluasi	Minggu 5–6	Hitung semua metrik, buat Confusion Matrix dan ROC Curve, analisis error, dokumentasi
Fase 4: Website	Minggu 7–8	Development Streamlit, integrasi model .h5, deploy ke Streamlit Cloud, finalisasi laporan UAS

7.2. Target Luaran

#	Luaran	Bentuk File	Target Selesai
1	Dataset terpreproses	.npy / folder gambar	Minggu 2
2	Notebook EDA	01_EDA.ipynb	Minggu 2
3	Model Baseline terlatih	baseline_vgg16.h5	Minggu 3
4	Model Usulan terlatih	dermaspot_model.h5	Minggu 4
5	Tabel komparasi eksperimen	results.csv	Minggu 5
6	Website DermaSpot	app.py (Streamlit)	Minggu 7
7	Laporan Akhir	laporan_akhir.pdf	Minggu 8

7.3. Kriteria Keberhasilan

1. Recall model usulan ≥ 85% pada data test
2. Recall model usulan secara signifikan lebih tinggi dari baseline (selisih ≥ 5%)
3. AUC-ROC ≥ 0.85
4. Inference time ≤ 3 detik di environment Streamlit
5. Website DermaSpot dapat diakses publik melalui Streamlit Cloud

7.4. Rencana Impelementasi (UAS)

Model terbaik (.h5) akan diintegrasikan ke dalam aplikasi website Streamlit dengan fitur:

1. Upload foto lesi kulit oleh pengguna
2. Preprocessing otomatis (resize & normalisasi)
3. Prediksi real-time dengan hasil: label risiko + confidence score
4. Rekomendasi tindak lanjut berdasarkan tingkat risiko
5. Deployment gratis melalui Streamlit Community Cloud

PIC: Dikerjakan secara individu oleh Rama Adhi Saputra (A11.2024.15847)

DAFTAR PUSTAKA

Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. Nature, 542(7639), 115–118. https://doi.org/10.1038/nature21056

Goyal, M., Knackstedt, T., Yan, S., & Hassanpour, S. (2020). Artificial intelligence-based image classification methods for diagnosis of skin cancer: challenges and opportunities. Computers in Biology and Medicine, 127, 104065. https://doi.org/10.1016/j.compbiomed.2020.104065

Chaturvedi, S. S., Tembhurne, J. V., & Diwan, T. (2022). A multi-class skin Cancer classification using deep convolutional neural networks. Multimedia Tools and Applications, 79(39), 1–21. https://doi.org/10.1007/s11042-020-09388-2

Kassem, M. A., Hosny, K. M., Damaševičius, R., & Eltoukhy, M. M. (2020). Machine learning and deep learning methods for skin lesion classification and diagnosis: a systematic review. Diagnostics, 11(8), 1390. https://doi.org/10.3390/diagnostics11081390

Tschandl, P., Rosendahl, C., & Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. Scientific Data, 5, 180161. https://doi.org/10.1038/sdata.2018.161